Étude de cas 4 : Centrale solaire

Jalon 1 : Prévoir la production avec un MLP

chapitre 1 - réseaux de neurones

M2 SDIA - Advanced Artificial Intelligence

Année universitaire 2026–2027

Objectif du jalon

Prévoir les six prochaines heures avec un perceptron multicouche, choisir l'activation de sortie et la perte, et mesurer ce que chaque groupe d'entrées apporte.

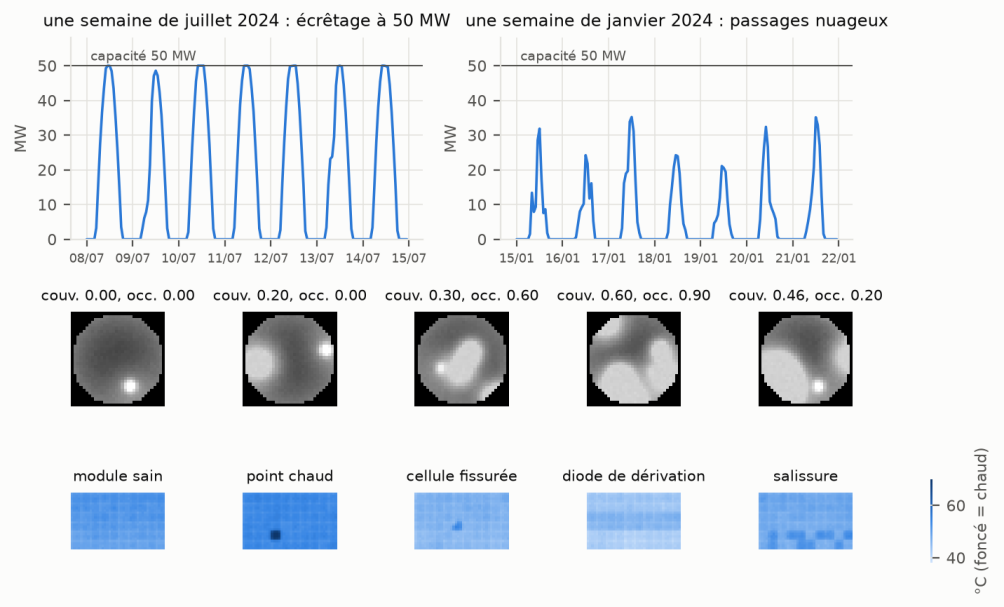
Jalon autonome : ce jalon ne suppose pas d'avoir terminé les jalons précédents. Il s'appuie uniquement sur le notebook de démarrage `uc4_demarrage.ipynb`, le dossier `data/` et le code de démarrage de la section 3. Vous pouvez repartir de votre propre travail antérieur, mais rien ne l'exige.
Environnement : Python 3, TensorFlow/Keras, scikit-learn ; Google Colab avec GPU recommandé.

1 Contexte

L'exploitant fictif *SolarDrâa* gère une centrale de 50 MW dans la région de Ouarzazate (site A, climat désertique). Chaque heure, il doit annoncer au gestionnaire du réseau sa production pour les heures $t+1$ à $t+6$; les écarts entre annonce et réalité sont pénalisés. Les nuages, les épisodes de poussière et l'encrassement des panneaux font varier la production ; par ciel clair en été, l'onduleur plafonne la puissance injectée à 50 MW (*écrêtage*).

Une caméra hémisphérique filme le ciel toutes les heures et une campagne de thermographie par drone a produit des images de modules, dont quelques-uns sont défectueux. Enfin, une seconde centrale de 20 MW vient d'être mise en service sur le littoral atlantique (site B, plus bas en latitude, brouillards matinaux) : on ne dispose que de deux mois d'historique pour l'entraînement.

L'étude de cas en cinq jalons : un jalon par chapitre du cours, rendu après le chapitre correspondant, puis une synthèse défendue à l'oral en fin de module (note de décision, prédictions sur le test caché, soutenance).



2 Données et cibles de ce jalon

Fichier	Contenu
`uc4_siteA.csv`	site A, 2023 à 2025, une ligne par heure : géométrie solaire, rayonnement mesuré, température, prévisions météo de la veille, jours depuis le dernier nettoyage, production
`uc4_siteB.csv`	site B, janvier à juin 2025, mêmes colonnes

Découpage imposé (temporel) : site A, entraînement jusqu'au 30/09/2024, validation d'octobre à décembre 2024, test en 2025 ; site B, entraînement en janvier et février, validation en mars, test d'avril à juin. Les erreurs de prévision ne sont comptées que sur les heures de jour. Les données sont simulées.

Cibles du cahier des charges concernées

Exigence	Mesure (ensemble de test)	Cible
Prévision du site A à 1 h	gain par rapport à la persistance intelligente	$\geq 0{,}12$
Prévision du site A	gain moyen sur les six horizons	$\geq 0{,}30$
Déploiement	taille du modèle de prévision	≤ 5 Mo

Le **gain** (*skill score*) vaut $1 - \mathrm{RMSE}_{\text{modèle}}/\mathrm{RMSE}_{\text{référence}}$, calculé sur les heures de jour. La référence est la *persistance intelligente* : $\hat{P}_{t+h} = P_t \cdot GHI^{cs}_{t+h}/GHI^{cs}_t$, où GHI^{cs} est le rayonnement par ciel clair (fonctions du notebook de démarrage). Ces cibles décrivent le système *final* : elles ne sont pas exigées à la fin de ce jalon. Mesurez-vous par rapport à elles et expliquez l'écart ; un écart argumenté vaut mieux qu'une cible atteinte sans explication.

3 Point de départ

Le notebook de démarrage construit les exemples de prévision (24 heures d'historique, grandeurs connues à l'avance pour $t+1$ à $t+6$, calendrier, jours depuis le nettoyage : 47 entrées), les références métier (persistance, persistance intelligente, veille) et un **MLP de référence** à sortie sigmoïde avec son tableau de bord (section 3).

Le code ci-dessous donne les groupes de colonnes pour les ablations, un constructeur de MLP paramétrable (activation de sortie, perte) et la fonction de gain par horizon.

Code de démarrage (fichier `uc4_jalon1_depart.py`)

```
# Étude de cas 4 - Jalon 1 : code de démarrage
# À exécuter à la suite du notebook de démarrage, exécuté en entier.

# Colonnes de EX[site]["X"] (fonction fabriquer_exemples), par groupe
GROUPES = {"historique": list(range(0, 24)),
           "ciel_clair": list(range(24, 30)),
           "nebulosite": list(range(30, 36)),
           "temperature": list(range(36, 42)),
           "calendrier": list(range(42, 46)),
           "nettoyage": [46]}

def mlp_prevision(n_entrees, activation="sigmoid", perte="mse"):
    e = keras.Input((n_entrees,))
    x = layers.Dense(64, activation="relu")(e)
    x = layers.Dense(32, activation="relu")(x)
    m = keras.Model(e, layers.Dense(H, activation=activation)(x))
    m.compile(keras.optimizers.Adam(1e-3), perte)
    return m

def gain(site, P, ens="va"):
    # gain par horizon sur l'ensemble ens ("va" ou "te") du site
    E = EX[site]
    Y, J = E["Y"][E[ens]], E["J"][E[ens]]
    ref = E["REF"]["persistance intelligente"][E[ens]]
    return 1 - (rmse_par_horizon(Y, P, J, CAPACITE[site])
                / rmse_par_horizon(Y, ref, J, CAPACITE[site]))

# Exemple d'ablation : sans la prévision de nébulosité
E = EX["A"]
garder = [j for j in range(E["X"].shape[1])
          if j not in GROUPES["nebulosite"]]
m = mlp_prevision(len(garder))
m.fit(E["X"][E["tr"]][:, garder], E["Y"][E["tr"]], epochs=30,
      batch_size=128, verbose=0,
      validation_data=(E["X"][E["va"]][:, garder], E["Y"][E["va"]]))
P = m.predict(E["X"][E["va"]][:, garder], verbose=0)
print("gain par horizon (validation) :", gain("A", P).round(3))

# Analyse des erreurs : heure et mois de chaque origine de prévision
t_va = pd.to_datetime(E["T"][E["va"]])
heure_va, mois_va = t_va.hour, t_va.month
```

4 Travail demandé

Jalon 1 : Prévoir la production avec un MLP

Notions mobilisées : perceptron multicouche, fonctions d'activation, fonctions de perte, rétropropagation, régularisation, courbes d'apprentissage, ablation d'entrées.

1. Reproduire la référence et analyser ses erreurs par heure de la journée (sur la validation), puis par mois (sur le test, en fin de jalon).
2. Comparer au moins trois couples (activation de sortie, perte) : linéaire, ReLU ou sigmoïde ; MSE, MAE ou Huber.
3. Mesurer l'apport de chaque groupe d'entrées (historique, nébulosité prévue, calendrier, jours depuis le nettoyage) par un tableau d'ablation.
4. Régulariser (dropout, L2, arrêt précoce) et justifier le réglage retenu par la validation.

Vérification théorique (à la main, puis vérifiée par le code)

1. Comptez les paramètres du MLP de référence (47 entrées, couches de 64 et 32 neurones, 6 sorties).
2. À 10 h, la production vaut 30 MW et le soleil est à 40° de hauteur ; à 11 h, il sera à 50°. Avec le modèle $GHI^{cs}(\alpha) = 1098 \sin\alpha \, e^{-0{,}057/\sin\alpha}$, calculez la prévision de la persistance intelligente pour 11 h.
3. Calculez la dérivée de la sigmoïde lorsque la sortie vaut 0,99. Que devient l'apprentissage sur les heures écrêtées ?

À justifier dans votre page de décisions

Le choix de l'activation de sortie et de la perte ; l'exclusion des heures de nuit de la métrique ; le découpage temporel plutôt qu'aléatoire.

5 À rendre à la fin du chapitre

Livrables du jalon 1

— le notebook du jalon, exécuté et reproductible (graine fixée, versions indiquées) ;
— le journal d'expériences à jour (fonction `journaliser` du notebook de démarrage, avec `jalon=1`), y compris les essais infructueux ;
— une page de décisions : tableau des résultats, choix retenus et justifications, réponses aux vérifications théoriques.

Protocole : tous les réglages se font sur la validation ; l'ensemble de test ne sert qu'une fois, à la fin du jalon, pour le modèle retenu. Ce jalon alimente la note de décision finale et la soutenance.