Étude de cas 4 : Centrale solaire

Jalon 2 : Voir le ciel et les panneaux

chapitre 2 - CNN et auto-encodeurs

M2 SDIA - Advanced Artificial Intelligence

Année universitaire 2026–2027

Objectif du jalon

Estimer l'état du ciel à partir des images de la caméra, s'en servir pour la prévision à court terme, et repérer les modules défectueux avec un auto-encodeur.

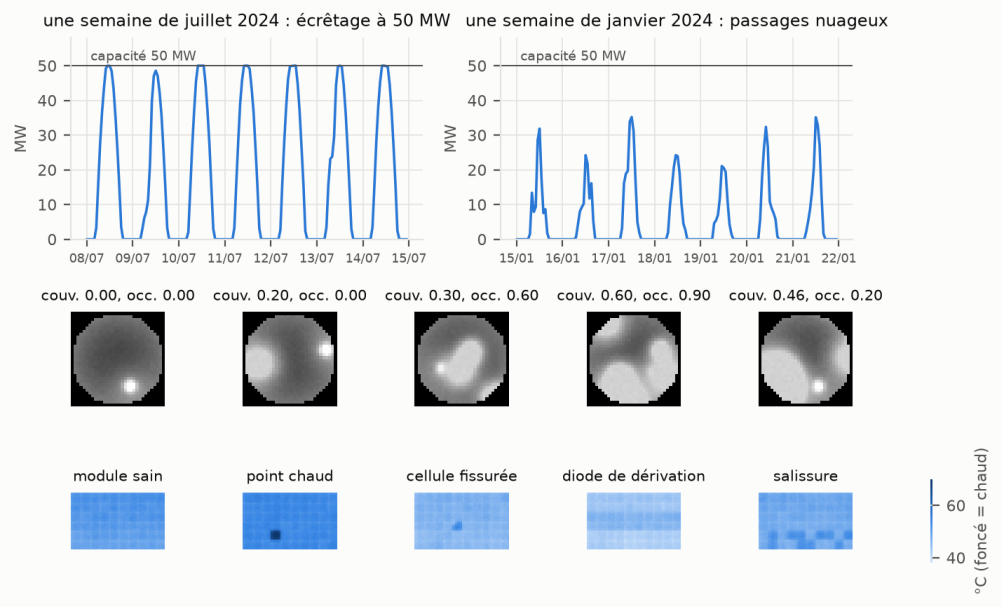
Jalon autonome : ce jalon ne suppose pas d'avoir terminé les jalons précédents. Il s'appuie uniquement sur le notebook de démarrage `uc4_demarrage.ipynb`, le dossier `data/` et le code de démarrage de la section 3. Vous pouvez repartir de votre propre travail antérieur, mais rien ne l'exige.
Environnement : Python 3, TensorFlow/Keras, scikit-learn ; Google Colab avec GPU recommandé.

1 Contexte

L'exploitant fictif *SolarDrâa* gère une centrale de 50 MW dans la région de Ouarzazate (site A, climat désertique). Chaque heure, il doit annoncer au gestionnaire du réseau sa production pour les heures $t+1$ à $t+6$; les écarts entre annonce et réalité sont pénalisés. Les nuages, les épisodes de poussière et l'encrassement des panneaux font varier la production ; par ciel clair en été, l'onduleur plafonne la puissance injectée à 50 MW (*écrêtage*).

Une caméra hémisphérique filme le ciel toutes les heures et une campagne de thermographie par drone a produit des images de modules, dont quelques-uns sont défectueux. Enfin, une seconde centrale de 20 MW vient d'être mise en service sur le littoral atlantique (site B, plus bas en latitude, brouillards matinaux) : on ne dispose que de deux mois d'historique pour l'entraînement.

L'étude de cas en cinq jalons : un jalon par chapitre du cours, rendu après le chapitre correspondant, puis une synthèse défendue à l'oral en fin de module (note de décision, prédictions sur le test caché, soutenance).



2 Données et cibles de ce jalon

Fichier	Contenu
`uc4_siteA.csv`	site A, 2023 à 2025, une ligne par heure : géométrie solaire, rayonnement mesuré, température, prévisions météo de la veille, jours depuis le dernier nettoyage, production
`uc4_ciel_A.npz`, `uc4_ciel_B.npz`	images 32×32 de la caméra (heures de jour), couverture nuageuse et occultation du soleil
`uc4_thermographie.npz`	images 24×40 en °C : modules sains pour l'entraînement et la validation, test avec quatre types de défauts

Découpage imposé (temporel) : site A, entraînement jusqu'au 30/09/2024, validation d'octobre à décembre 2024, test en 2025 ; site B, entraînement en janvier et février, validation en mars, test d'avril à juin. Les erreurs de prévision ne sont comptées que sur les heures de jour. Les données sont simulées.

Cibles du cahier des charges concernées

Exigence	Mesure (ensemble de test)	Cible
Prévision du site A à 1 h	gain par rapport à la persistance intelligente	$\geq 0{,}12$
Occultation du soleil (caméra)	erreur absolue moyenne	$\leq 0{,}10$
Thermographie	AUC	$\geq 0{,}98$
Thermographie : cellules fissurées	détection pour 5 % de fausses alertes	$\geq 0{,}85$

Le **gain** (*skill score*) vaut $1 - \mathrm{RMSE}_{\text{modèle}}/\mathrm{RMSE}_{\text{référence}}$, calculé sur les heures de jour. La référence est la *persistance intelligente* : $\hat{P}_{t+h} = P_t \cdot GHI^{cs}_{t+h}/GHI^{cs}_t$, où GHI^{cs} est le rayonnement par ciel clair (fonctions du notebook de démarrage). Ces cibles décrivent le système *final* : elles ne sont pas exigées à la fin de ce jalon. Mesurez-vous par rapport

à elles et expliquez l'écart ; un écart argumenté vaut mieux qu'une cible atteinte sans explication.

3 Point de départ

Le notebook de démarrage fournit les séries, les images du ciel (avec la couverture et l'occultation mesurées), les thermographies, les **règles simples de référence** (seuil sur les pixels pour la couverture ; luminosité au point du soleil pour l'occultation ; « maximum moins médiane » pour la thermographie) et le MLP de prévision de référence.

Le code ci-dessous prépare les images du ciel avec leur découpage temporel, la correspondance entre chaque origine de prévision et les images prises à t et $t-1$, puis les thermographies normalisées avec le seuil à 5 % de fausses alertes.

Code de démarrage (fichier `uc4_jalon2_depart.py`)

```
# Étude de cas 4 - Jalon 2 : code de démarrage
# À exécuter à la suite du notebook de démarrage, exécuté en entier.

# 1. Images du ciel du site A : entrées, cibles, découpage temporel imposé
C = CIEL["A"]
IMG = C["X"][..., None].astype("float32") / 255.0
Y_CIEL = np.column_stack([C["couverture"], C["occultation"]])
t_img = SERIES["A"].horodatage.values[C["heure"]]
tr_c, va_c, te_c = decoupe(t_img, "A")

# 2. Pour le prévisionniste : indice de l'image prise à t et à t-1 pour
#    chaque origine de prévision de EX["A"] (-1 : pas d'image, la nuit)
ligne_vers_image = np.full(len(SERIES["A"]), -1)
ligne_vers_image[C["heure"]] = np.arange(len(C["heure"]))
origines = np.arange(24, len(SERIES["A"]) - H)     # lignes de EX["A"]
img_t, img_tm1 = ligne_vers_image[origines], ligne_vers_image[origines - 1]
print("origines avec une image à t et à t-1 :",
      np.mean((img_t >= 0) & (img_tm1 >= 0)))

# 3. Thermographie (°C) : modules sains en entraînement et en validation,
#    test avec défauts ; normalisation calculée sur l'entraînement
TH = {s: THERMO["X_" + s][..., None].astype("float32")
      for s in ["train", "val", "test"]}
mu_th, sd_th = TH["train"].mean(), TH["train"].std()
TH = {s: (x - mu_th) / sd_th for s, x in TH.items()}

def seuil_5FA(score_val):
    # seuil pour 5 % de fausses alertes sur des modules sains
    return np.percentile(score_val, 95)
# détection par type : THERMO["defaut_test"] (0 = sain, 1 à 4 = défauts)
```

4 Travail demandé

Jalon 2 : Voir le ciel et les panneaux

Notions mobilisées : convolution, pooling, dimensions et paramètres, champ réceptif, auto-encodeur, erreur de reconstruction, détection d'anomalies, seuil.

1. Concevoir un CNN qui estime la couverture nuageuse et l'occultation du soleil à partir d'une image ; comparer aux règles simples du notebook.
2. Ajouter les estimations du CNN (aux instants t et $t-1$) aux entrées du MLP de prévision. Le gain à 1 h s'améliore-t-il ? Et à 6 h ? Essayez aussi de prédire directement l'occultation à $t+1$ à partir de la paire d'images $(t-1,\, t)$, qui montre le déplacement des nuages.
3. Entraîner un auto-encodeur convolutif sur les modules sains ; fixer le seuil d'alerte pour 5 % de fausses alertes sur la validation ; mesurer la détection par type de défaut.
4. Comparer au moins deux scores d'anomalie (erreur de reconstruction moyenne ou maximale) et deux tailles de goulot.

Vérification théorique (à la main, puis vérifiée par le code)

1. Pour votre CNN du ciel, calculez les dimensions après chaque couche et le nombre de paramètres, puis vérifiez avec `summary()`. Calculez son champ réceptif et comparez-le à la taille du soleil et d'un nuage sur l'image 32×32.
2. Une image thermique 24×40 traverse deux convolutions de pas 2 avec 16 puis 32 filtres (`padding="same"`). Donnez la taille du tenseur obtenu et le taux de compression si le goulot est une couche dense de 32 neurones.

À justifier dans votre page de décisions

Pourquoi un auto-encodeur sans goulot étroit ne détecte presque rien ; pourquoi l'erreur maximale convient mieux aux défauts localisés ; pourquoi le seuil est fixé sur la validation.

5 À rendre à la fin du chapitre

Livrables du jalon 2

— le notebook du jalon, exécuté et reproductible (graine fixée, versions indiquées) ;
— le journal d'expériences à jour (fonction `journaliser` du notebook de démarrage, avec `jalon=2`), y compris les essais infructueux ;
— une page de décisions : tableau des résultats, choix retenus et justifications, réponses aux vérifications théoriques.

Protocole : tous les réglages se font sur la validation ; l'ensemble de test ne sert qu'une fois, à la fin du jalon, pour le modèle retenu. Ce jalon alimente la note de décision finale et la soutenance.