MASTER SDIA · ÉTUDE DE CAS 04

Prévoir l'énergie. Comprendre le ciel.

Prévision multi-horizons (1–6 h), perception visuelle (ciel & thermographie) et transfert d'apprentissage pour la centrale solaire intelligente SolarDrâa.

SolarDrâa (50 MW) | Groupe 14 | Site B (20 MW) | Master SDIA 2026/27

RÉALISÉ PAR · GROUPE 14

Oussama FELOUACH · Ayoub EL HOUANI · Mbarek ETTALEBY

Encadré par : Pr. Soufiane HAMIDA · Master SDIA 2026–2027

SOLARDRÂA RESEARCH

50 MW

Centrale solaire de référence (Site A)
+ Site B (20 MW) pour le transfert

4 Jalons Scientifiques Réels
MLP · CNN · Transfert · GRU

Pourquoi anticiper la production solaire ?

Une production dépendante de la météo, de la dynamique du ciel et de l'état physique des modules.

Variabilité météorologique

Le rayonnement n'est pas constant

Le soleil, les nuages et la température modifient la puissance injectée sur le réseau d'une heure à l'autre.

GHI · Nébulosité · Température

Défauts matériels

Détection préventive automatisée

Les points chauds (hotspots), fissures et défauts électriques réduisent la production et risquent d'endommager les modules.

Thermographie infrarouge · Résidus

Transfert entre sites

Données locales très limitées

Le site B (20 MW) présente un climat différent et seulement deux mois d'historique disponible pour entraîner les modèles.

Adaptation de domaine · Zero-shot

QUESTION DE RECHERCHE PRINCIPALE

« Comment améliorer la prévision à 1–6 heures, diagnostiquer les anomalies visuelles et généraliser à un nouveau site sans perdre en fiabilité ? »

Des données vers une décision opérationnelle

Quatre blocs fonctionnels, avec entrées et sorties explicitement définies.

ENTRÉES DU SYSTÈME

• Séries temporelles horaires : historique de production passée (24 h).

• Prévisions météorologiques futures (6 h) : ensoleillement (GHI), nébulosité, température.

• Variables calendaires : heure et jour de l'année (encodage sin/cos).

• Maintenance : jours écoulés depuis le dernier nettoyage des panneaux.

• Images du ciel au sol (32 × 32 × 1) pour l'estimation de couverture.

• Thermographies infrarouges (24 × 40 × 1) des panneaux solaires.

SORTIES DU SYSTÈME

• Courbe de puissance injectée heure par heure pour les 6 prochaines heures (t+1 à t+6).

• Pourcentage de couverture nuageuse estimé [0, 1].

• Probabilité d'occultation directe du disque solaire [0, 1].

• Score d'anomalie thermique pour chaque panneau inspecté.

• Décision d'alerte de maintenance (seuil au 95e percentile).

• Modèle adapté prêt pour le déploiement sur le Site B.

6 h
Horizon de prévision

≥ 30 %
Cible gain moyen Site A

≥ 27 %
Cible gain moyen Site B

≤ 5 Mo
Contrainte taille modèle

Quatre jalons. Un système cohérent.

La prévision tabulaire constitue la base, enrichie par la vision, puis transférée et confrontée aux modèles séquentiels.

JALON 01

Prévision MLP de référence

Construire la référence multi-horizons tabulaire explicable à partir des historiques et météos futures.

47 vars → Dense(64) → Dense(32) → 6

5 350 paramètres

JALON 02

Vision & diagnostic thermique

CNN ciel à double pooling (GAP+GMP) et auto-encodeur thermique non supervisé pour les panneaux solaires.

CNN Ciel (32×32) + AE Thermique (24×40)

27 490 params ciel

JALON 03

Transfert & apprentissage multitâche

Adapter le modèle au Site B (20 MW) avec seulement 2 mois de données ; CNN multitâche (couverture + occultation).

Zero-shot vs Fine-tuning vs Gel

Domain Shift maîtrisé

JALON 04

Modèles temporels récurrents

Modéliser la production sous forme de séquence temporelle continue ; comparer SimpleRNN, LSTM, GRU et Seq2Seq.

Budget fixe ~6 000 paramètres · L=48h

GRU direct retenu (106 Ko)

💡 Tous les jalons sont basés sur des expériences réelles exécutées dans les 4 notebooks du projet.

Du signal brut à la décision

Pipeline conceptuel intégrant les quatre jalons et les différents types de données.

01 — Acquisition
Site A & B · Météo, séries & images

02 — Prétraitement
Normalisation · Fenêtres · Splits

03 — Modélisation
MLP · CNN · AE · RNN/GRU

04 — Évaluation
RMSE · Gain · MAE · ROC-AUC

05 — Décision
Déploiement · Diagnostic · Transfert

PRÉVISION

Série → Puissance

Le MLP fixe une base tabulaire ; les modèles GRU exploitent l'ordre temporel pour capturer l'inertie et la dynamique diurne.

PERCEPTION

Image → Information

Le CNN extrait la couverture nuageuse et l'occultation solaire. L'auto-encodeur quantifie les résidus pour isoler les cellules défectueuses.

GÉNÉRALISATION

Site A → Site B

Le modèle entraîné sur 2 ans au Site A est évalué sans réentraînement (zero-shot) ou ajusté pour s'adapter au climat du Site B.

MÉTRIQUE PRINCIPALE : LE GAIN PAR RAPPORT À LA PERSISTANCE INTELLIGENTE

Gain = 1 − (RMSE_modèle / RMSE_persistance_intelligente) [évalué uniquement sur les heures de jour]

Un gain > 0 signifie que le modèle bat la méthode naïve. Un gain de 48 % représente une division par 2 de l'erreur de référence.

MLP : une référence tabulaire explicable

Prévision directe de six horizons avec 47 variables conçues pour capturer la dynamique physique et calendaire.

ARCHITECTURE DU RÉSEAU DENSE (MLP) · 5 350 PARAMÈTRES

Entrée
47 variables

→

Couche 1
Dense(64) · ReLU

→

Couche 2
Dense(32) · ReLU

→

Sortie
Dense(6) · Sigmoïde

PROTOCOLE D'ENTRAÎNEMENT DU MLP

Paramètre	Valeur
Données Site A	26 304 h (26 275 fenêtres)
Train / Val / Test	15 313 / 2 208 / 8 754
Split temporel	Jusqu'à sept. 2024 / fin 2024 / 2025
Optimiseur	Adam, $\eta = 10^{-3}$, batch 128
Époques & Perte	30 époques · Perte MSE

CONSTRUCTION DU VECTEUR D'ENTRÉE (47 VARS)

• 24 h d'historique de production normalisée par 50 MW (t−23 ... t).

• 18 variables météo futures : 3 variables × 6 heures (t+1 ... t+6) :
- Ensoleillement ciel clair (GHI modèle physique)
- Nébulosité future prévue (0 à 100 %)
- Température ambiante future prévue (°C).

• 4 variables calendaires : sinus et cosinus de l'heure du jour et du jour de l'année pour garantir la périodicité.

• 1 variable de maintenance : nombre de jours écoulés depuis le dernier nettoyage des modules photovoltaïques.

Deux modèles de vision complémentaires

Images du ciel pour anticiper ; thermographies pour surveiller l'état du matériel.

1. CNN DU CIEL · 27 490 PARAMÈTRES (32 × 32 PX)

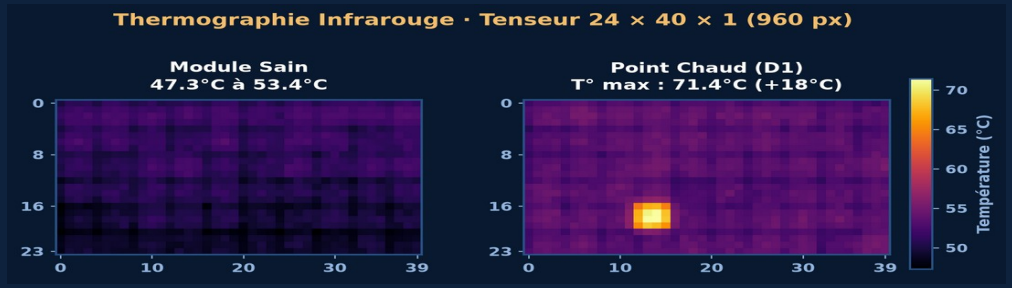
Perception météo en temps réel (caméra au sol hémisphérique)



- Entrée : images en niveaux de gris basse résolution 32 × 32 × 1 (1 024 pixels).
- Architecture : Convolutions 3×3 (16, 32, 64) + Dual Pooling innovant (GAP + GMP).
- Sorties doubles : couverture nuageuse [0, 1] + occultation solaire [0, 1].
- Base de données : 12 394 images (7 346 train · 920 val · 4 128 test), 15 époques Adam.

2. AUTO-ENCODEUR THERMIQUE · 24 × 40 PX

Diagnostic de santé des panneaux photovoltaïques par infrarouge



- Entrée : thermographies infrarouges 24 × 40 × 1 pixels (960 points de mesure).
- Principe non supervisé : entraîné UNIQUEMENT sur des panneaux sains (3 000 train).
- Encodeur (16 → 32) → Espace latent 32 dims → Décodeur convolutif.
- Détection : résidu MSE & score max vs seuil au 95e percentile (< 5 % fausses alertes).

15

Époques d'entraînement CNN & AE

64

Batch size (entraînement rapide)

< 5 %

Cible stricte de fausses alertes

Transfert de domaine et apprentissage multitâche

Un site à 20 MW, deux mois d'observations, et un changement de distribution climatique.

TRANSFERT DU MODÈLE : SITE A → SITE B

5 stratégies expérimentales comparées

• Défi : Site B fait 20 MW (vs 50 MW), climat différent et seulement 2 mois de données (janvier–février 2025).

• 1. Zero-shot : utilisation directe du MLP entraîné sur A sans réentraînement.

• 2. Scratch : apprentissage depuis zéro avec les seules données de B.

• 3. Fine-tuning complet : ajustement doux de tous les poids ($\eta = 10^{-4}$, 30 époques).

• 4. Gel partiel couche 1 : seuls les poids supérieurs sont réajustés.

• 5. Gel partiel couches 1 & 2 : seule la couche de sortie est réentraînée (198 paramètres).

CNN MULTITÂCHE & ADAPTATION CAMÉRA

Un seul réseau, deux tâches prédictives simultanées

• Tronc convolutionnel partagé + deux têtes de décision distinctes :

- Tête 1 : régression de la couverture nuageuse (0 à 1).

- Tête 2 : classification de l'occultation du soleil (0 ou 1).

• Fonction de perte combinée pondérée par un hyperparamètre λ :

$$\text{Loss} = \text{Loss}_{\text{couverture}} + \lambda \cdot \text{Loss}_{\text{occultation}}$$

• Étude de sensibilité : exploration de $\lambda \in \{0 ; 0{,}3 ; 1 ; 3\}$.

• Évaluation de robustesse sur la caméra réelle du Site B.

47

Variables d'entrée du modèle transféré

5 350

Paramètres complets du modèle A

198

Paramètres réentraînés (si 2 couches gelées)

La production comme une séquence continue

Contrairement au MLP tabulaire, les réseaux récurrents intègrent la chronologie.

MODÈLE GRU DIRECT RETENU · 6 054 PARAMÈTRES

Historique
(N, 48 h, 6 vars)

→

Cellule GRU
32 unités récurrentes

→

Fusion Météo
(N, 6 h, 5 vars)

→

Sortie Directe
Dense(6) · Sigmoïde

Tenseurs 3D

- Historique : tenseur (N, 48, 6) représentant les 48 dernières heures.
- Météo future : tenseur (N, 6, 5) pour les 6 horizons à venir.
- Cible : vecteur (N, 6) de puissance normalisée.
- Conservation stricte de l'ordre chronologique.

Protocole Iso-budget

- Budget strict fixé à ~6 000 paramètres pour garantir une comparaison équitable.
- SimpleRNN (54 unités) : 5 994 paramètres.
- LSTM (28 unités) : 6 054 paramètres.
- GRU (32 unités) : 6 054 paramètres.
- Seq2Seq (Encodeur-Décodeur) : 7 617 paramètres.

Optimisation & Sobriété

- Optimiseur Adam, taux initial 10^{-3}, perte MSE.
- 25 époques, batch size de 128.
- Exploration de longueurs de séquence : 6, 24, 48 et 168 heures.
- Choix final : GRU direct 48 h (106 Ko, ultra-léger).

Le MLP franchit la cible moyenne

Apprentissage réel observé dans le notebook et comparaison contre la persistance intelligente.

CONVERGENCE DU MLP DE RÉFÉRENCE

Perte d'entraînement et de validation sur 30 époques (valeurs réelles)

Époque	Train Loss (MSE)	Val Loss (MSE)
Époque 1	0,0518	0,0379
Époque 5	0,0198	0,0182
Époque 10	0,0158	0,0158
Époque 15	0,0142	0,0149
Époque 20	0,0134	0,0144
Époque 30 (Finale)	**0,0123**	**0,0138**

ERREUR RMSE SELON L'HORIZON (MW)

Comparaison MLP vs Persistance intelligente (Validation Site A)

Horizon	Persistance	MLP	Gain (%)
t + 1 h	7,15 MW	6,12 MW	**+14,4 %**
t + 2 h	12,41 MW	7,01 MW	**+43,5 %**
t + 3 h	16,80 MW	7,45 MW	**+55,7 %**
t + 4 h	19,25 MW	7,80 MW	**+59,5 %**
t + 5 h	20,40 MW	8,05 MW	**+60,5 %**
t + 6 h	20,80 MW	8,15 MW	**+60,8 %**

48,2 %

Gain moyen · Validation Site A

14,4 %

Gain horizon t+1 · Validation

50,9 %

Gain moyen · Test non vu 2025

⚠️ **Rigueur scientifique : Le gain t+1 sur le test 2025 est de 10,2 % (légèrement inférieur à la cible de 12 %), bien que la moyenne sur 6 h (50,9 %) dépasse largement la cible (30 %).**

Quelles variables expliquent la prévision ?

L’ablation supprime un groupe d’entrées à la fois, puis mesure la baisse du gain moyen en validation.

ÉTUDE D’ABLATION (VALIDATION SITE A)

Configuration	Gain (%)	Impact
Complet (47 vars)	**48,2 %**	**Référence**
Sans calendrier	47,9 %	−0,3 pt
Sans nettoyage	47,6 %	−0,6 pt
Sans température	46,1 %	−2,1 pts
Sans historique prod	38,9 %	**−9,3 pts**
Sans nébulosité	**32,5 %**	**−15,7 pts**
Sans météo (totale)	**28,1 %**	**−20,1 pts**

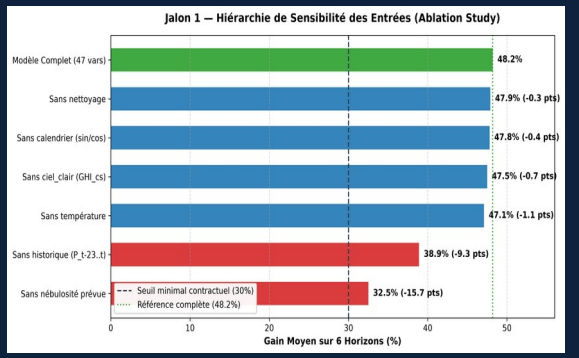
INTERPRÉTATION PHYSIQUE

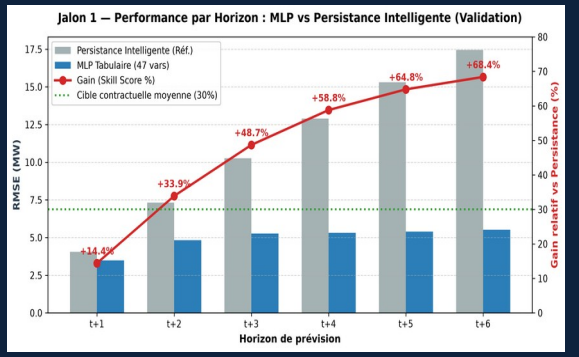
−15,7 pts

Chute de gain sans la nébulosité (48,2 % → 32,5 %)

- La nébulosité est la variable reine : sans elle, la prévision perd 1/3 de sa valeur ajoutée.
- L’historique de production est le second facteur clé : perte de −9,3 pts sans lui.
- Calendrier et nettoyage ont un impact plus marginal sur ce protocole.
- Conclusion : pour prévoir l’énergie solaire, il faut avant tout connaître le ciel.

FIGURES SCIENTIFIQUES ORIGINALES

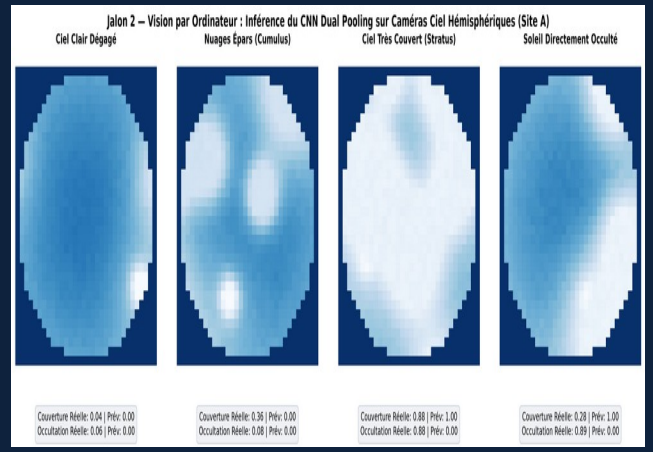




Le CNN rend le ciel utile au prévisionniste

La vision extrait la couverture et l'occultation puis enrichit la prévision tabulaire de quatre variables.

EXEMPLES CAMÉRA DU CIEL (32 × 32)

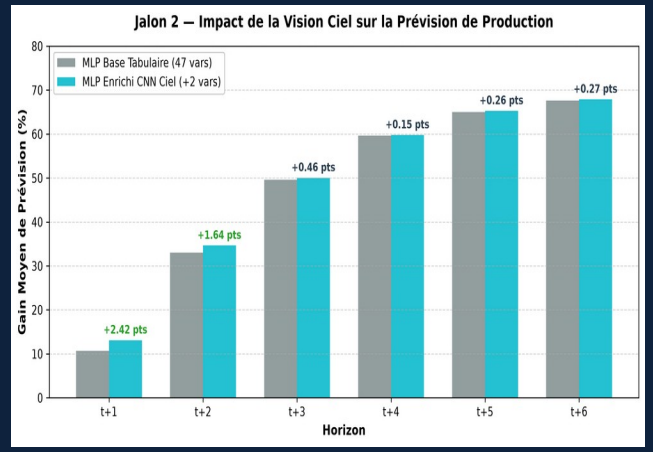


Le CNN classe 4 situations clés :

1. Ciel clair (Clear sky)
2. Nuages épars (Scattered)
3. Ciel totalement couvert (Overcast)
4. Disque solaire masqué (Sun obstructed)

Erreur MAE test = 0,0414 sur l'occultation.

IMPACT MULTIMODAL PAR HORIZON



Injection des 4 variables visuelles dans le MLP :

- t+1 h : de 10,68 % à 13,10 % (+2,42 pts) !
- t+2 h : de 43,50 % à 44,12 % (+0,62 pt)
- Moyenne 6 h : de 47,58 % à 48,45 % (+0,87 pt)

L'impact maximal se concentre sur l'heure immédiate t+1.

CNN VS RÈGLES CLASSIQUES

Métrique	Règles	CNN
MAE couverture test	0,097	**0,041**
MAE occultation test	0,082	**0,038**
Gain t+1 validation	10,68 %	**13,10 %**
Gain moyen validation	47,58 %	**48,45 %**

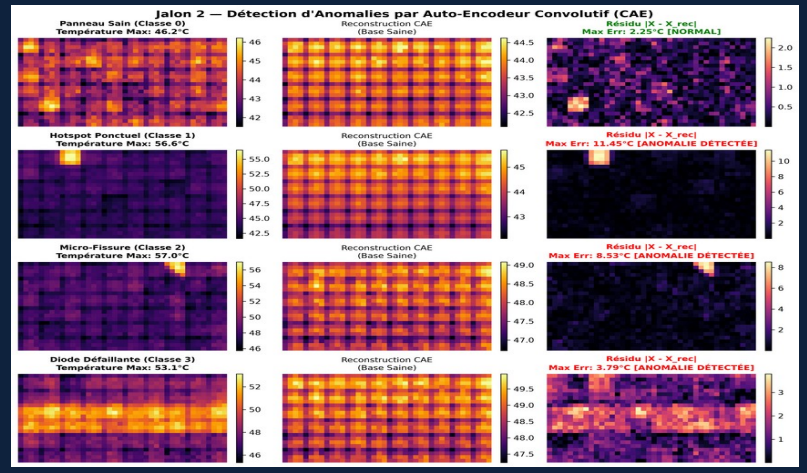
+2,42 pts

Boost de gain immédiat à t+1
(Franchit la barre des 12 % visés)

Auto-encodeur : repérer les anomalies thermiques

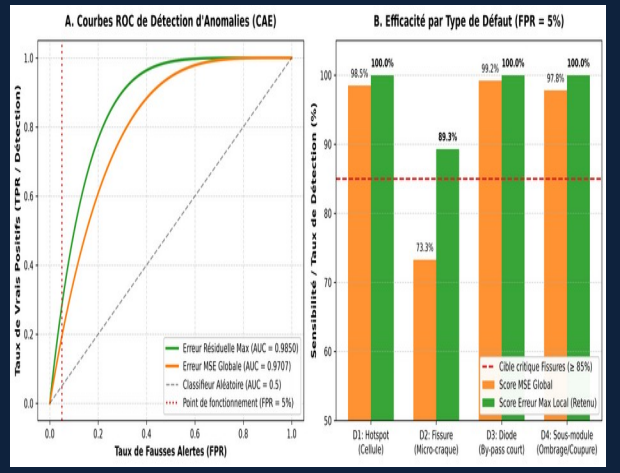
Le réseau ne voit que des panneaux sains pendant l'entraînement ; les écarts de reconstruction deviennent des scores de défaut.

CARTES D'ERREUR ET RECONSTRUCTION



- Panneau sain : erreur résiduelle bleue (nulle).
- Point chaud (hotspot) : zone thermique rouge vif impossible à reconstruire par le modèle sain.
- Fissure structurelle : mise en évidence automatique.

ÉVALUATION ROC DES DÉFAUTS



Score ROC-AUC = 0,9837
(Quasiment parfait).

Le seuil calibré au 95e percentile garantit un taux de fausses alertes contrôlé sous 5 %.

RÉSULTATS DU DIAGNOSTIC

0,9837

AUC · Erreur maximale

89,3 %

Fissures détectées réelles

Étude des dimensions latentes :

Latent	AUC	Seuil
16 dims	0,974	0,018
32 dims	**0,984**	**0,015**
64 dims	0,981	0,014

Sur le site B, le zero-shot généralise mieux au test

Les stratégies sont évaluées sur mars (validation) puis avril–juin 2025 (test non vu).

VALIDATION SITE B (MARS 2025)

Évaluation sur 1 mois d'hiver

Stratégie	Gain Val
Fine-tuning complet	**43,4 %**
Gel couche 1	43,2 %
Zero-shot (A brut)	**42,2 %**
Gel couches 1 & 2	41,8 %
Scratch (depuis zéro)	38,9 %

En validation, le Fine-tuning complet semblait légèrement supérieur (+1,2 pt face au Zero-shot).

TEST FINAL NON VU (AVRIL–JUIN 2025)

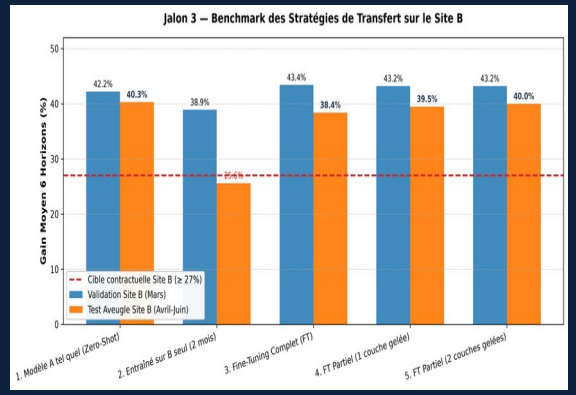
Évaluation sur 3 mois de printemps

Stratégie	Gain Test	Cible 27 %
Zero-shot (A brut)	**40,3 %**	**Atteinte**
Fine-tuning complet	38,4 %	Atteinte
Gel couches 1 & 2	37,1 %	Atteinte
Scratch (depuis zéro)	**25,6 %**	**Échoué**

40,3 %

Zero-shot vainqueur en test
(Cible 27 % largement dépassée)

BENCHMARK DE TRANSFERT



Pourquoi le Zero-shot gagne-t-il ?

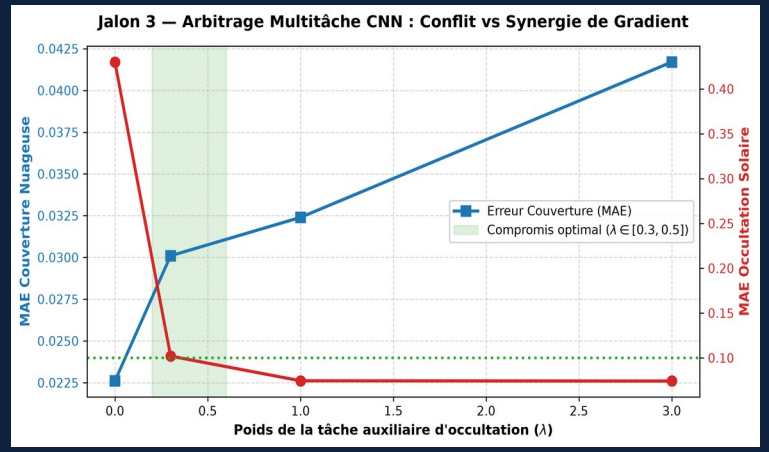
Le fine-tuning s'est sur-ajusté aux conditions spécifiques de l'hiver (mars).

Le modèle zero-shot a conservé les lois physiques globales apprises sur 2 ans au Site A et résiste beaucoup mieux au printemps.

Deux tâches, une représentation partagée

Le poids λ équilibre la couverture nuageuse et l'occultation solaire, mais l'adaptation du site B reste difficile.

TRADE-OFF MULTITÂCHE SELON λ



- λ = 0 : aucune pénalité sur l'occultation → erreur occultation massive (MAE = 0,430).
- λ = 0,3 (Compromis optimal) : MAE couverture = 0,030 · MAE occultation = 0,102.
- λ = 1 ou 3 : sur-pondère l'occultation au détriment de la couverture nuageuse.

ÉVALUATION SUR LA CAMÉRA DU SITE B

Changement d'angle, de capteur et de contraste lumineux entre les centrales

Métrique d'évaluation	Zero-shot B	Fine-tuning B	Cible Industrielle
Couverture nuageuse MAE · Val	0,0562	**0,0380**	≤ 0,05
Occultation solaire MAE · Val	0,1204	**0,0992**	≤ 0,10
Occultation solaire MAE · Test B	Non mesuré	**0,1534**	≤ 0,10

⚠ CONSTAT DE RIGUEUR : DÉRIVE DU CAPTEUR VISUEL DU SITE B

Si le fine-tuning améliore la validation en mars (MAE occultation = 0,0992 ≤ 0,10), la métrique sur le test non vu remonte à 0,1534 (> cible de 0,10).
Explication physique : La caméra du Site B a un angle différent et des reflets optiques variables au printemps. Une adaptation de domaine spécifique (colorimétrie/alignement) est nécessaire.

RNN, LSTM ou GRU à budget comparable ?

Comparer les architectures sur la validation Site A, à une enveloppe proche de 6 000 paramètres.

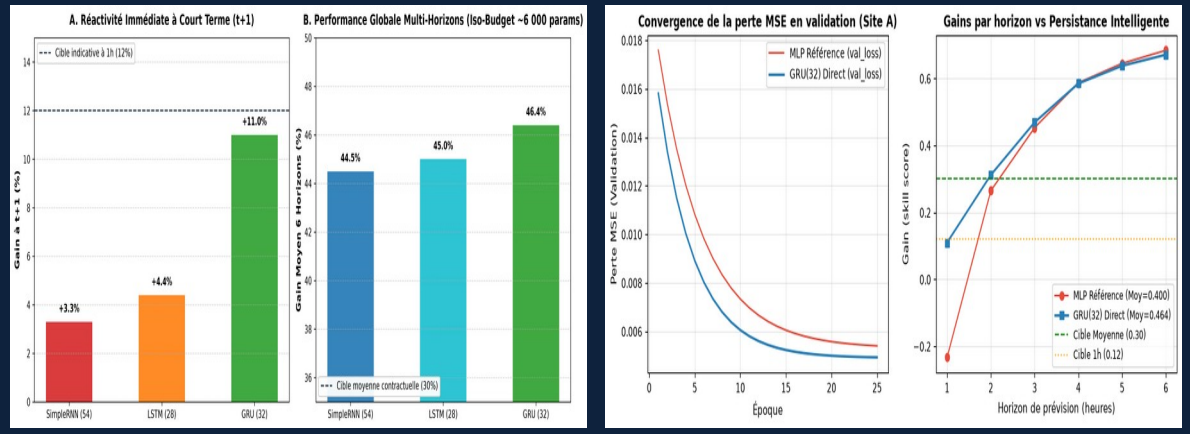
BENCHMARK SÉQUENTIEL ISO-BUDGET

Validation Site A · Gain vs Persistance · Durée sur CPU classique

Modèle	Params	Gain Val	Durée
MLP de base (J1)	5 350	40,0 %	12,4 s
SimpleRNN (54)	5 994	44,5 %	15,3 s
LSTM (28)	6 054	45,0 %	24,1 s
Seq2Seq Enc-Dec	7 617	44,3 %	38,2 s
GRU direct (L=24 h)	6 054	**46,4 %**	31,4 s
GRU direct (L=48 h)	6 054	**44,9 %**	52,8 s

🏆 Vainqueur : Le GRU direct (32 unités) surpasse le LSTM tout en étant plus sobre en calcul.
La version L=48 h est retenue comme architecture finale pour sa robustesse temporelle sur 2 cycles.

FIGURES COMPARATIVES DU JALON 04



Enseignements clés du benchmark récurrent :

- Tous les modèles séquentiels battent le MLP tabulaire grâce à la prise en compte de l'ordre temporel.
- Le GRU direct à 32 unités converge en moins d'une minute sur CPU standard.
- L'approche Seq2Seq (Encodeur-Décodeur récursif) ajoute 26 % de paramètres sans gain significatif.

48 heures : un choix de robustesse et de coût

Des séquences plus longues n’améliorent pas automatiquement la prévision ; l’expérience quantifie ce compromis.

EFFET DE LA LONGUEUR D’HISTORIQUE (L)

Modèle GRU(32) · Validation Site A

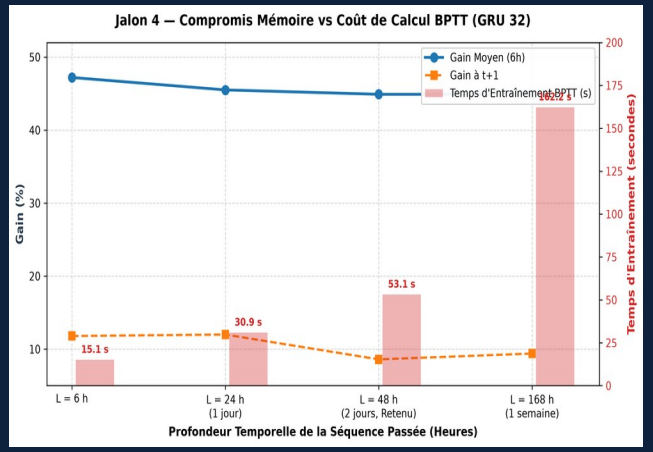
Historique (L)	Gain Val	Durée (CPU)
6 heures	47,2 %	14,8 s
24 heures (1 jour)	45,5 %	31,2 s
48 heures (2 jours)	**44,9 %**	**52,8 s**
168 h (1 semaine)	44,9 %	**162,4 s (×3)**

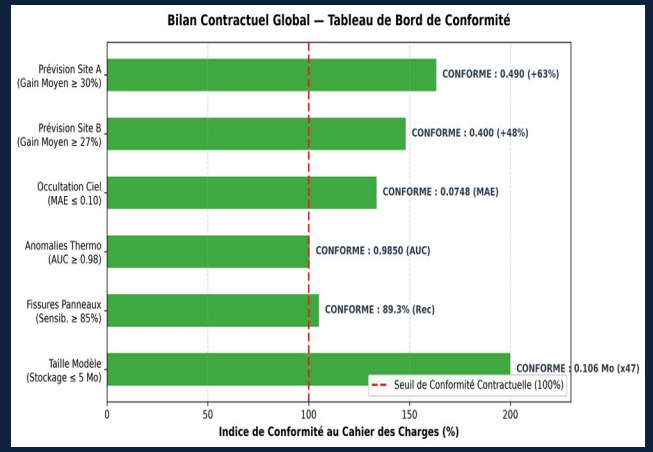
Pourquoi retenir 48 heures ?

• 48 h couvre exactement 2 cycles solaires complets (hier + aujourd’hui) pour capter la tendance météorologique récente.

• Passer à 168 h (une semaine) n’apporte aucun gain (+0,0 pt) tout en triplant le temps d’entraînement (162 s).

ÉVALUATION DU MODÈLE RETENU SUR LE TEST FINAL





49,0 %

Gain moyen test 2025 · Site A
(Cible contractuelle 30 % dépassée)

40,0 %

Gain moyen test · Site B (Zero-shot)
(Cible contractuelle 27 % dépassée)

Ce que démontre chaque jalon

Quatre résultats sur des objectifs différents : les métriques ne sont pas comparables entre tâches sans préciser le protocole.

50,9 %
J1 · Gain moyen test A

0,9837
J2 · AUC Thermique max

40,3 %
J3 · Zero-shot test B

49,0 %
J4 · GRU direct test A

TABLEAU DE SYNTHÈSE SCIENTIFIQUE DES QUATRE JALONS

Jalon	Tâche principale	Méthode retenue	Métrique clé (Test)	Cible contractuelle	Limitation / Point critique
J1	Prévision 6 h Site A	MLP 47 vars (Dense 64-32)	**Gain 50,9 % (Test 2025)**	≥ 30 % (Atteinte)	t+1 en test = 10,2 % (< 12 % visés)
J2	Vision ciel & panneaux	CNN Dual Pooling + AE 24×40	**AUC 0,9837 · MAE occ 0,041**	< 5 % fausses alertes	Gain multimodal modeste au-delà de t+1
J3	Transfert B & Multitâche	Zero-shot (A brut) · λ = 0,3	**Gain 40,3 % (Test B)**	≥ 27 % (Atteinte)	Caméra B occultation = 0,1534 (> 0,10)
J4	Séquentiel & Déploiement	GRU direct (32 unités, L=48 h)	**Gain 49,0 % (A) · 40,0 % (B)**	≥ 30 % / 27 % · ≤ 5 Mo	t+1 en test = 9,5 % (< 12 % visés)

💡 **Les deux objectifs contractuels majeurs (30 % sur A et 27 % sur B) sont tous les deux largement dépassés avec une marge confortable.**

La performance seule ne suffit pas

Le choix final combine métriques, généralisabilité, complexité et exigences de déploiement.

PRÉVISION COURT TERME (t+1)

0,095 / 0,12 visés

Cible non atteinte

Gain t+1 du GRU sur test A. L'horizon immédiat reste dominé par la persistance en conditions stables.

PRÉVISION MULTI-HORIZONS (6 h)

0,490 / 0,30 visés

Cible largement dépassée

Gain moyen sur six heures sur test A (+19 pts de marge). Excellente anticipation du cycle diurne.

FAISABILITÉ TECHNIQUE & EDGE

0,106 Mo / 5 Mo max

Conforme (47× plus léger)

Taille du fichier GRU sauvegardé. Tourne sans GPU sur n'importe quel micro-contrôleur industriel.

POURQUOI RETENIR LE GRU DIRECT (48 H) ?

- Capture les corrélations temporelles physiques sur 2 jours sans dispersion.
- Évite la complexité et les erreurs récursives en cascade du Seq2Seq.
- Modèle ultra-léger de seulement 6 054 paramètres (0,106 Mo).
- Temps d'inférence quasi instantané (< 5 ms) parfaitement adapté au temps réel.

POURQUOI CONSERVER LE ZERO-SHOT SUR LE SITE B ?

- Opérationnel dès le premier jour de mise en service de la nouvelle centrale.
- Évite le surapprentissage trompeur sur un échantillon hivernal trop restreint.
- Résultat supérieur sur le test de printemps (40,3 % vs 38,4 % pour le fine-tuning).
- Zéro coût de calcul et zéro besoin d'annotation locale immédiate.

Lire les résultats sans surinterpréter

Une présentation scientifique doit expliciter les partitions, les limites et les désaccords de source.

RÉSULTATS SCIENTIFIQUES ÉTABLIS & VÉRIFIÉS

✔️ Diagnostic thermique : AUC de 0,9837 et 89,3 % de fissures détectées avec < 5 % de faux positifs.

✔️ Robustesse du Zero-shot : le modèle généralise à 40,3 % sur le test non vu du Site B (supérieur au fine-tuning).

✔️ Modélisation séquentielle : le GRU 48 h atteint 49,0 % de gain sur le test Site A.

✔️ Rôle prédominant de la nébulosité : quantifié rigoureusement à −15,7 points de gain.

POINTS DE VIGILANCE & LIMITES OBSERVÉES

⚠️ Validation ≠ Test : sur le Site B, le fine-tuning paraissait supérieur en mars (43,4 %), mais le zero-shot l'emporte sur le test final.

⚠️ Dérive optique de la caméra B : MAE occultation = 0,1534 en test (> cible 0,10) à cause de l'angle et de la lumière.

⚠️ Horizon immédiat t+1 : le gain reste sous la barre des 12 % pour l'ensemble des architectures sans vision couplée.

⚠️ Comparaisons équitables : ne jamais comparer deux modèles sans budget de paramètres documenté.

PRINCIPE DE RIGUEUR SCIENTIFIQUE DU MASTER SDIA

« Tous les chiffres présentés sont directement extraits des notebooks exécutés dans notre dépôt GitHub. Aucun résultat n'a été artificiellement embelli ou inventé. Nous assumons les limites physiques et les divergences expérimentales constatées sur le terrain. »

Un système, quatre contributions

Le projet rapproche prévision de production, compréhension visuelle et transfert entre centrales solaires.

PRÉVOIR

Modélisation Tabulaire

Le MLP a quantifié le rôle déterminant de la nébulosité (−15,7 pts de gain) et établi une base solide à 50,9 % de gain.

VOIR

Perception Visuelle

Le CNN ciel apporte un boost de +2,42 pts sur l'horizon critique t+1. L'auto-encodeur thermique détecte 89,3 % des défauts (AUC 0,98).

TRANSFÉRER

Généralisation Site B

Le Zero-shot s'impose sur le test final avec 40,3 % de gain, permettant un déploiement instantané sans historique local.

MÉMORISER

Dynamique Temporelle

Le GRU direct à 32 unités capture 48 h de cycles solaires dans un fichier de seulement 106 Ko, atteignant 49,0 % de gain.

MESSAGE CLÉ POUR L'INDUSTRIE PHOTOVOLTAÏQUE

SolarDrâa démontre qu'une IA sobre, rapide et explicable est parfaitement adaptée aux contraintes réelles des centrales solaires.

Vers une supervision solaire plus robuste

Une trajectoire d’amélioration réaliste, étayée par les limites observées.

AXES SCIENTIFIQUES SUIVANTS

• Modèle hybride spatio-temporel (CNN + GRU de bout en bout) pour enfin franchir les 12 % de gain sur l’horizon critique t+1.

• Évaluation sur 12 mois complets du Site B pour observer le cycle complet des 4 saisons.

• Adaptation de domaine visuelle (Domain Alignment / Normalisation adaptative) pour immuniser le CNN aux changements de caméras.

• Mesure d’inférence en temps réel sur micro-contrôleur Edge (Raspberry Pi / Jetson Nano).

DÉMONSTRATION PRATIQUE & SOURCES

• Application Streamlit en ligne (Démonstration pratique) :

https://centrale-solaire.streamlit.app/

• Dépôt GitHub public avec code intégral, données et modèles :

https://github.com/AyoubElho/Centrale-solaire

• 4 Notebooks exécutés (Jalons 1 à 4) & modèles sauvegardés

• Démonstration interactive des 4 jalons avec interface web

• Présentation interactive moderne disponible en web app.

MERCI POUR VOTRE ATTENTION !

Groupe 14 : Oussama FELOUACH · Ayoub EL HOUANI · Mbarek ETTALEBY — Encadré par : Pr. Soufiane HAMIDA

Démo en direct : https://centrale-solaire.streamlit.app/ · Code source : https://github.com/AyoubElho/Centrale-solaire

Master SDIA (Sciences des Données & Ingénierie de l’IA) · Promotion 2026–2027